

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Informe Small Data

Paso 1: Selección del dataset

DATASET: Fraudes Viáticos

Al abrir el archivo en Orange, el widget Data table muestra 10.000 filas y 14 columnas, con 2 meta-attributes. La variable target es "gasto_sospechoso" con valores 0 (Legítimo) y 1 (Sospechoso / requiere revisión).

El widget Distributions muestra que el 68% tiene valor 0 y el 32% tiene valor 1 → hay un desbalance moderado.

El tipo de problema queda definido: clasificación binaria. Queremos predecir una de dos clases posibles.

Paso 2: Definición del problema de negocio

Problema: Predecir si un gasto rendido por un empleado es sospechoso, para que el equipo de Auditoría Interna enfoque su revisión manual en los casos de mayor riesgo, drásticamente bajando el tiempo necesario de la revisión manual.

¿Quién usa el modelo? El equipo de Auditoría Interna lo usa para reducir el tiempo dedicado a revisiones manuales de cada caso.

¿Cuál es el error más costoso?

Costo de un falso positivo: se pierde "únicamente" el tiempo de un auditor, que sería un costo de oportunidad para el auditor.

Costo de un falso negativo: el sospechoso queda sin revisión y la empresa pierde directamente desde su presupuesto destinado a viáticos comerciales. Es probable que los empleados con gastos sospechosos, si no son detectados, sigan abusando de la política, aumentando las pérdidas aún más.



En conclusión, el falso negativo es claramente el error más costoso, y el modelo tiene que priorizar la métrica de "Recall" a la hora de evaluar los gastos sospechosos, vamos a buscar minimizar los falsos negativos.

	Monto ARS	% del total
Gasto Legítimo	609,462,678.28	77%
Gasto Sospechoso	178,360,659.21	23%
Total	787,823,337.49	100%

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Paso 3 - EDA (pre y post procesamiento)


Hipótesis 1 (Aprovechamiento del Tope de Política): Los gastos que superan o se acercan al tope máximo permitido por la política interna tienen una probabilidad mayor de ser sospechosos que los que se mantienen dentro del límite. Creemos que se declara el gasto muy cerca, pero debajo de lo que permite la política, y se quedan con el resto del dinero, porque en realidad fue más bajo el gasto.




Hipótesis 2 (Monto declarado): La probabilidad de gastos sospechosos es mucho más alta cuando el monto declarado es mayor. A partir de superar los 250.000 ARS la probabilidad de encontrar un gasto sospechoso sube hasta aproximadamente 40% en promedio, comparado con probabilidades que rara vez exceden del 20% cuando se tratan de gastos menores a 250.000\$ en los montos debajo de 250.000 ARS.

→ Crear probabilidad de que un gasto sea sospechoso según el monto declarado y analizar con un Histograma.

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul




Hipótesis 3 (Gastos sin comprobante): Si el gasto no tiene un comprobante asociado, es más probable que sea sospechoso. Con comprobante vemos una probabilidad del 15,6% de ser sospechosos, mientras los gastos sin comprobante tienen más del doble de probabilidad de ser sospechosos, aproximadamente 38,2%.



Hipótesis 4: Los gastos fuera del horario de oficina tienen más probabilidad de ser sospechosos, ya que no hay personas que revisen esos gastos en el momento. Sin embargo descartamos esta hipótesis como un factor fuerte, ya que al observar los datos vemos que no hay mucha diferencia en las probabilidades, es tomada en cuenta igualmente dentro del modelo ya que aporta una mejor (pero no muy significativa por lo mencionado anteriormente).


Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul



Hallazgos:

Dia de Semana:

Los domingos cuentan con una probabilidad de tener gastos sospechosos alrededor de un 10% más que otros días de la semana (aprox. 27% contra un promedio cerca de 17% durante la semana)




Historial de Rechazos:

Aunque sospechamos que la historia de gastos rechazados de un usuario ayudaría a predecir gastos sospechosos y que quien fue rechazado en el pasado tiene más riesgo de ser sospechoso, los datos dicen lo contrario. Esto es un hallazgo contra-intuitivo y


Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

sorprendente, la sospecha sigue en un nivel muy parecido independientemente de la cantidad de rechazos previos.




Jerarquía de empleado y departamento:

Al mismo tiempo el análisis visual de los departamentos y la jerarquía de los empleados se puede encontrar que el sospechoso no está concentrado en ningún rol ni departamento específico, sino que atraviesa a toda la organización. Eso también es un descubrimiento sorprendente, ya que en un principio sospechamos que los empleados de mayor jerarquía dispondrán de un presupuesto mayor para abusar de él, o que áreas que realizan más viajes tendrían mayores gastos sospechosos.




Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul



Método de pago:


Podemos observar que el método de pago no tiene ninguna relación con que el gasto sea sospechoso. Sea en efectivo o con la tarjeta corporativa, la probabilidad de que el gasto sea sospechoso es la misma o muy parecida, aproximadamente un 20% de probabilidad.



Cuit válido:

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

También pudimos ver que si el cuit al que se imputa el gasto es válido o no, no se relaciona con la probabilidad de que el gasto sea sospechoso.



Conclusión:

En conclusión, suponemos que las variables que mayor peso tendrán en el modelo predictivo serán las siguientes:

- `monto_declarado_ars`
- `dia_semana`
- `ratio_monto_limite`
- `tiene_comprobante`

Estas no serán las únicas incluidas, ya que hay otras variables que mejoran los indicadores del modelo pero en cantidades pequeñas, por eso es que no es notable la relación “variable”-“gasto sospechoso” en los gráficos.

Paso 4 - Preprocesamiento y selección de variables

Detección y tratamiento de valores nulos:

Primero, la variable de `id_gasto` se cambió a metadata, ya que es un identificador continuo que no sirve para el análisis y entrenamiento.

`tiene_comprobante` fue recodificado de (Sí/No) a (1/0) usando el widget “edit domain” para que el modelo pueda procesarlo con mayor eficiencia.

`hora_gasto` se mantiene como variable predictora en formato datetime.

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Limpieza de formato de fechas: `fecha_gasto` fue estandarizada a formato único `DD/MM/YYYY`. Se optó por mantenerla como metadata y utilizar `dia_semana` como proxy temporal, dado que un análisis de estacionalidad excede el scope de este trabajo.

Limpieza de valores nulos: Solamente notamos inconsistencias de formato en la variable de `cuit_proveedor` que se queda como metadata. Con la variable nueva de `cuit_valido` se soluciona el problema, ya que un valor nulo en este campo podría dar la sospecha de un gasto sospechoso, y no debería ser eliminado, sino utilizado para el resto del análisis. Decidimos crear una feature mediante el widget “formula” tomando como `cuit` válido (1) un número de 11 dígitos (por ejemplo: 30876952809) y cómo `cuit` no válido (0) los siguientes ejemplos detectados en la base de datos (N/A,12345,30-ABC-9).

Se crearon dos variables nuevas mediante Feature Constructor (Feature Engineering):

1. `ratio_monto_limite`

Definición: `ratio_monto_limite = monto_declarado_ars / limite_politica_ars` → mide la magnitud de la superación del límite, no sólo si ocurrió y captura si el gasto se acerca o supera el límite de política. La cercanía al límite podría significar un gasto sospechoso.


<1: el monto no supera el límite de la política

=1: el monto es exactamente el límite máximo

>1: el monto supera el límite permitido

2. `cuit_valido`

Definición: `cuit_valido = len(str(cuit_proveedor)) == 11` → flag binaria que detecta CUITs inválidos (N/A,12345, 30-ABC-9) como potenciales indicadores de gastos sospechosos. Creamos esta variable pensando que el hecho de que el gasto tenga un `cuit` de proveedor invalido puede aumentar las chances de que ese gasto sea sospechoso.



Se crearon 4 variables nuevas mediante Python Script (Feature Engineering):

1. `excede_limite`

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Definición: `excede_limite = 1 si monto_declarado_ars >`

`limite_politica_ars` → Detecta gastos que superan el tope máximo permitido por la política interna. El modelo no tenía esta información de forma explícita, antes tenía el monto y el límite por separado, pero no la comparación directa entre ambos. Al dársela ya calculada, el modelo no tiene que "descubirla" solo.

2. `fuera_horario`

Definición: `fuera_horario = 1 si hora < 9 o hora >= 17, o día es`

`Sábado o Domingo` → Detecta gastos realizados fuera de la jornada laboral o en fines de semana. Una reunión con cliente o visita comercial ocurre durante la jornada laboral. Un gasto a las 2 de la mañana un domingo es inherentemente sospechoso porque no tiene contexto comercial que lo justifique. Esta variable le da al modelo información temporal que antes estaba "escondida" dentro de `hora_gasto` y `dia_semana` por separado.

3. `sin_comp_alto_monto`

Definición: `sin_comp_alto_monto = 1 si tiene_comprobante = 'No' Y`

`monto >= percentil 75` → Combina la ausencia de comprobante con un monto alto de gasto, logrando obtener una irregularidad doble. Un gasto sin comprobante de \$4000 puede ser un café olvidado. Pero un gasto sin comprobante de \$150.000 es una irregularidad grave que el auditor no puede verificar. La variable captura ese riesgo compuesto que el modelo no podía inferir solo.

4. `es_domingo`

Definición: `es_domingo = 1 si es 'Domingo', 0 para cualquier otro día`

→ Detecta los gastos realizados los días Domingo. Creamos esta variable para el modelo pensando que nos iba a mejorar el modelo, al notar que los días Domingo tenían una probabilidad más alta a tener gastos sospechosos que todos los demás días, pero nos dimos cuenta que esta feature no nos terminó sirviendo ya que empeoraba los resultados, creemos que es porque ya con tener en cuenta la variable de `dia_semana`, el modelo ya logra captar esta posible inconsistencia.


Eliminación de variables irrelevantes:

- `categoría_gasto` fue eliminada del modelo ya que su información está completamente capturada por `limite_politica_ars`, una variable numérica que además permite calcular `ratio_monto_limite`. Mantener ambas sería información redundante, ya que la categoría del gasto directamente establece el monto máximo permitido.
- `jerarquia_empleado`, `departamento`, `distancia_oficina_km`, `comentarios_longitud`, `sin_comp_alto_monto` fueron eliminadas del modelo porque son poco relevantes (no se correlacionan con el hecho de que los gastos sean sospechosos o no) y empeoran el modelo.


Análisis de Outliers:

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Usando el widget de “Boxplot” se nota que hay algunos Outliers, pero ninguno que sea imposible. Al contrario, algunos outliers parecen que contribuyen a la sospecha de los gastos, por ejemplo un monto altamente superior a lo que permite la política de la empresa, que es una señal muy fuerte de que el gasto no está justificado. Por ejemplo, un gasto de 450.000 es muy inusual, pero no imposible.



El ratio confirmó casos donde el gasto casi duplica el límite permitido, valores que el modelo debe aprender a detectar, así no deberíamos eliminarlos para que el modelo pueda aprender de estos casos extremos.



El Box Plot calcula el Student's t-test, que mide si la diferencia entre clases es real o producto del azar. Usando $p > 0.05$ como umbral de no-significancia, `ratio_monto_limite`, `monto_declarado_ars` y `limite_politica_ars` mostraron diferencias altamente significativas ($p=0.000$) y se mantienen en el modelo. `comentarios_longitud`, `distancia_oficina_km` e `historial_rechazos` como variables numericas superaron el umbral y fueron excluidas via Select Columns. Las variables excluidas fueron determinadas con el análisis disponible hasta este momento. En iteraciones futuras se podría reevaluar su inclusión o explorar nuevas transformaciones para mejorar el modelo.

Paso 5 - Modelado

Para entrenar el modelo predictivo, decidimos balancear los datos de gastos sospechosos contra los no sospechosos, en un principio intentamos hacerlo con las funciones propias de Orange, como “balance class distribution” pero no parecía funcionar realmente, ya que los indicadores seguían siendo relativamente bajos.

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Como solución, decidimos crear un script de python que balancee los datos en proporciones iguales, con el fin de que el modelo sepa identificar ambos gastos correctamente.

Modelos seleccionados:

Modelo 1: Regresión logística

Es un modelo estadístico que estima la probabilidad de que una observación pertenezca a una determinada categoría (por ejemplo, sospechoso o no sospechoso) a partir de las variables explicativas. Funciona asignando un peso a cada variable y combinándolas para calcular una probabilidad entre 0 y 1. Es simple, interpretable y suele utilizarse como modelo base.

Modelo 2: Random Forest

Es un conjunto de múltiples árboles de decisión contruidos a partir de distintas muestras aleatorias de los datos y subconjuntos de variables. Funciona generando muchos árboles de forma independiente y combinando sus predicciones mediante votación (clasificación) o promedio (regresión). Esto mejora la precisión y reduce el riesgo de sobreajuste.

Modelo 3: Gradient Boosting

Es un método de ensamble que construye árboles de decisión de manera secuencial. Funciona entrenando cada nuevo árbol para corregir los errores cometidos por los árboles anteriores, de modo que el modelo mejora progresivamente su capacidad predictiva. Suele ofrecer un alto rendimiento en problemas complejos, aunque requiere un ajuste más cuidadoso de sus parámetros.

Paso 6 - Evaluación

TEST AND SCORE:

NO SOSPECHOSO:

Evaluation results for target 0						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest (2)	0.988	0.924	0.920	0.975	0.871	0.854
Gradient Boosting (1)	0.834	0.787	0.774	0.822	0.731	0.577
Logistic Regression	0.750	0.693	0.670	0.723	0.624	0.389

PROMEDIO:

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Evaluation results for target (None, show average over classes) ▾						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest (2)	0.988	0.924	0.924	0.929	0.924	0.854
Gradient Boosting (1)	0.833	0.787	0.786	0.790	0.787	0.577
Logistic Regression	0.750	0.693	0.691	0.696	0.693	0.389

SOSPECHOSO:

Evaluation results for target 1 ▾						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest (2)	0.988	0.924	0.928	0.884	0.978	0.854
Gradient Boosting (1)	0.834	0.787	0.798	0.758	0.842	0.577
Logistic Regression	0.750	0.693	0.712	0.669	0.761	0.389

AUC — Capacidad de distinguir entre sospechoso y no sospechoso

- **Random Forest: 0.988** → En el 98.8% de los casos el algoritmo logra diferenciar eficazmente un gasto sospechoso de uno legítimo
- **Gradient Boosting: 0.834** → En el 83.4% de los casos distingue adecuadamente ambos tipos de registros
- **Logistic Regression: 0.750** → Solo en el 75% de las instancias consigue discriminarlos correctamente

El indicador AUC es global por modelo y no posee variaciones según la clase analizada.

RECALL

Clase 1 — Sospechosos

- **Random Forest: 0.978** → De cada 100 gastos sospechosos reales, identifica 98. Se omiten apenas 2
- **Gradient Boosting: 0.842** → De cada 100 gastos sospechosos reales, identifica 84. Se omiten 16
- **Logistic Regression: 0.761** → De cada 100 gastos sospechosos reales, identifica 76. Se omiten 24

Clase 0 — No sospechosos

- **Random Forest: 0.871** → De cada 100 gastos legítimos, clasifica bien 87 y deriva 13 a auditoría innecesariamente

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

- **Gradient Boosting: 0.731** → De cada 100 gastos legítimos, clasifica bien 73 y deriva 27 a auditoría innecesariamente
- **Logistic Regression: 0.624** → De cada 100 gastos legítimos, clasifica bien solo 62 y deriva 38 a auditoría innecesariamente

Average — Promedio entre ambas clases

- **Random Forest: 0.924** → En promedio, de cada 100 gastos totales, logra clasificar adecuadamente 92
 - **Gradient Boosting: 0.787** → En promedio, de cada 100 gastos totales, logra clasificar adecuadamente 79
 - **Logistic Regression: 0.693** → En promedio, de cada 100 gastos totales, logra clasificar adecuadamente solo 69
-

PRECISIÓN

Clase 1 — Sospechosos

- **Random Forest: 0.884** → De cada 100 alertas de sospecha, 88 son casos reales. Los otros 12 son errores de detección
- **Gradient Boosting: 0.758** → De cada 100 alertas de sospecha, 76 son casos reales y 24 resultan falsas alarmas
- **Logistic Regression: 0.669** → De cada 100 alertas de sospecha, solo 67 son casos reales. Los otros 33 son gastos legítimos

Clase 0 — No sospechosos

- **Gradient Boosting: 0.822** → De cada 100 casos marcados como normales, 82 lo son. 18 son irregularidades no captadas
- **Random Forest: 0.975** → De cada 100 casos marcados como normales, 97 lo son. Solo 3 son irregularidades no captadas
- **Logistic Regression: 0.723** → De cada 100 casos marcados como normales, 72 lo son. 28 son irregularidades no captadas

Average — Promedio entre ambas clases

- **Random Forest: 0.929** → En promedio, de cada 100 marcaciones de cualquier tipo, 93 están correctamente asignadas
 - **Gradient Boosting: 0.790** → En promedio, de cada 100 marcaciones de cualquier tipo, 79 están correctamente asignadas
 - **Logistic Regression: 0.696** → En promedio, de cada 100 marcaciones de cualquier tipo, 70 están correctamente asignadas
-

F1

Clase 1 — Sospechosos

- **Random Forest: 0.928** → Presenta el balance ideal para auditoría: alta detección (Recall 0.978) y precisión sólida (Prec 0.884)

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

- **Gradient Boosting: 0.798** → Logra captar bien el sospechoso (Recall 0.842) aunque con una precisión algo menor (Prec 0.758)
- **Logistic Regression: 0.712** → Su rendimiento se ve penalizado por una precisión reducida (0.669) pese a su Recall moderado

Clase 0 — No sospechosos

- **Random Forest: 0.920** → Resulta el más eficiente en la gestión de registros normales, con margen de error mínimo
- **Gradient Boosting: 0.774** → Exhibe un equilibrio aceptable, derivando más casos a revisión que el modelo anterior
- **Logistic Regression: 0.670** → Es el menos eficiente en esta categoría, generando excesivas revisiones manuales evitables

Average — Promedio entre ambas clases

- **Random Forest: 0.924** → Obtiene el mejor balance general con un desempeño robusto en ambas clases analizadas
- **Gradient Boosting: 0.786** → Muestra un promedio general favorable, ocultando ligeras deficiencias en la clase sospechosa
- **Logistic Regression: 0.691** → Refleja el indicador más bajo, evidenciando limitaciones en la clasificación de ambas clases

PREDICTIONS:

PROMEDIO:

☒ Show performance scores		Target class: (Average over classes) ▾				
Model	AUC	CA	F1	Prec	Recall	MCC
Gradient Boosting (1)	0.813	0.748	0.773	0.850	0.748	0.461
Random Forest (2)	0.800	0.801	0.803	0.805	0.801	0.370
Logistic Regression	0.749	0.636	0.675	0.800	0.636	0.293

NO SOSPECHOSO:

☒ Show performance scores		Target class: 0 ▾				
Model	AUC	CA	F1	Prec	Recall	MCC
Gradient Boosting (1)	0.813	0.748	0.823	0.951	0.725	0.461
Random Forest (2)	0.800	0.801	0.876	0.881	0.871	0.370
Logistic Regression	0.749	0.636	0.729	0.916	0.605	0.293

SOSPECHOSO:

Show performance scores		Target class: 1				
Model	AUC	CA	F1	Prec	Recall	MCC
Gradient Boosting (1)	0.813	0.748	0.562	0.422	0.844	0.461
Random Forest (2)	0.800	0.801	0.494	0.483	0.505	0.370
Logistic Regression	0.749	0.636	0.447	0.315	0.766	0.293

AUC — Capacidad de distinguir entre sospechoso y no sospechoso

- **Gradient Boosting: 0.813** → En el 81.3% de los casos el modelo logra distinguir correctamente un gasto sospechoso de uno no sospechoso
- **Random Forest: 0.800** → En el 80% de los casos distingue correctamente ambos tipos de gasto
- **Logistic Regression: 0.749** → Solo en el 74.9% de los casos logra distinguirlos correctamente

El AUC es único por modelo, no varía por clase, por eso no tiene desglose en 0, 1 y average

RECALL

Clase 1 — Sospechosos

- **Gradient Boosting: 0.844** → De cada 100 gastos realmente sospechosos, detecta 84. Se pierden 16
- **Random Forest: 0.505** → De cada 100 gastos realmente sospechosos, detecta apenas 50. Se pierden 50
- **Logistic Regression: 0.766** → De cada 100 gastos realmente sospechosos, detecta 76. Se pierden 24

Clase 0 — No sospechosos

- **Gradient Boosting: 0.725** → De cada 100 gastos normales reales, clasifica bien 72 y manda 28 a revisión innecesariamente
- **Random Forest: 0.871** → De cada 100 gastos normales reales, clasifica bien 87 y solo manda 13 a revisión innecesariamente
- **Logistic Regression: 0.605** → De cada 100 gastos normales reales, clasifica bien solo 60 y manda 40 a revisión innecesariamente

Average — Promedio entre ambas clases

- **Gradient Boosting: 0.748** → En promedio, de cada 100 gastos de cualquier clase, clasifica correctamente 74

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

- **Random Forest: 0.801** → En promedio, de cada 100 gastos de cualquier clase, clasifica correctamente 80
 - **Logistic Regression: 0.636** → En promedio, de cada 100 gastos de cualquier clase, clasifica correctamente solo 63
-

PRECISIÓN

Clase 1 — Sospechosos

- **Gradient Boosting: 0.422** → De cada 100 gastos que el modelo marca como sospechosos, solo 42 son sospechosos reales. Los otros 58 son gastos normales marcados por error
- **Random Forest: 0.483** → De cada 100 alertas de sospecha, 48 son sospechosos reales y 52 son falsas alarmas
- **Logistic Regression: 0.315** → De cada 100 alertas de sospecha, solo 31 son sospechosos reales. Los otros 69 son gastos normales

Clase 0 — No sospechosos

- **Gradient Boosting: 0.951** → De cada 100 gastos marcados como normales, 95 efectivamente lo son. Solo 5 son sospechosos que pasaron sin ser detectados
- **Random Forest: 0.881** → De cada 100 gastos marcados como normales, 88 efectivamente lo son. 12 son sospechosos no detectados
- **Logistic Regression: 0.916** → De cada 100 gastos marcados como normales, 91 efectivamente lo son. 9 son sospechosos no detectados

Average — Promedio entre ambas clases

- **Gradient Boosting: 0.850** → En promedio, de cada 100 gastos marcados en cualquier clase, 85 están correctamente clasificados
 - **Random Forest: 0.805** → En promedio, de cada 100 gastos marcados en cualquier clase, 80 están correctamente clasificados
 - **Logistic Regression: 0.800** → En promedio, de cada 100 gastos marcados en cualquier clase, 80 están correctamente clasificados
-

F1

Clase 1 — Sospechosos

- **Gradient Boosting: 0.562** → Detecta bien los sospechosos (Recall 0.844) pero genera muchas falsas alarmas (Prec 0.422), el F1 refleja ese desbalance
- **Random Forest: 0.494** → Ni detecta bien los sospechosos (Recall 0.505) ni tiene buena precisión (Prec 0.483), el peor balance real para auditoría
- **Logistic Regression: 0.447** → Tiene el peor F1: precisión muy baja (0.315) arrastra el resultado aunque el Recall sea moderado (0.766)

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Clase 0 — No sospechosos

- **Gradient Boosting: 0.823** → Muy buen balance clasificando gastos normales
- **Random Forest: 0.876** → El mejor de los tres clasificando gastos normales, casi no comete errores en esta clase
- **Logistic Regression: 0.729** → El peor de los tres en gastos normales, manda demasiados a revisión innecesariamente

Average — Promedio entre ambas clases

- **Gradient Boosting: 0.773** → En promedio entre ambas clases, logra un buen balance general gracias a su fortaleza en clase 0
- **Random Forest: 0.803** → El mejor F1 promedio de los tres, aunque esconde su debilidad crítica en clase 1
- **Logistic Regression: 0.675** → El peor F1 promedio, refleja un desempeño deficiente en ambas clases

Nomograma: Regresión Logística

Variables con peso predictivo real:

1. **monto_declarado_ars**: la más importante. A mayor monto declarado, mayor probabilidad de fraude. Confirma H2 del EDA
2. **limite_politica_ars**: segunda. El modelo detecta cuando el límite es bajo pero el monto es alto, patrón central de H1
3. **hora_gasto**: tercera. Gastos en horarios extremos (madrugada o noche) aumentan significativamente la probabilidad. El rango amplio en segundos le da mucha variación al modelo para detectar este patrón
4. **excede_limite**: variable de feature engineering confirmada como relevante. Superar el tope es señal directa de irregularidad
5. **tiene_comprobante**: sin comprobante sube la probabilidad de fraude. Confirma H3

Variables con peso casi nulo:

- **dia_semana, fuera_horario, cuit_valido, metodo_pago** y las restantes. Regresión Logística no encontró señal significativa. Importante aclarar: esto no significa que sean irrelevantes en general, sino que **Regresión Logística no puede capturar relaciones no lineales**. Gradient Boosting puede estar extrayendo señal de estas variables que Regresión Logística ignora

Matriz de confusión - Gradient Boosting

		Predicted		
		0	1	Σ
Actual	0	1171	445	1616
	1	60	324	384
Σ		1231	769	2000

Explicacion en terminos numericos:

El modelo evaluó 2.000 gastos en total. De los 384 sospechosos reales, detectó correctamente 324 (recall 84%) y se le escaparon 60. De los 1616 legítimos, clasificó bien 1171, pero generó 445 falsas alarmas. La precisión sobre los sospechosos detectados es del 42%, es decir, de cada 10 gastos que el modelo marca como sospechoso, solo 4 son sospechosos reales.

Explicacion en terminos de negocio:

El modelo es útil para su propósito principal, reducir el trabajo manual del equipo auditor. Sin el modelo, el equipo tendría que revisar los 2.000 gastos. Con el modelo, solo revisa los 769 que fueron marcados como sospechosos demostrando una reducción del 61% en la carga de trabajo.

Dentro de esos 769, hay 324 sospechosos reales capturados por el modelo y 445 falsas alarmas. Eso significa que el equipo auditor va a invertir tiempo revisando gastos legítimos, pero ninguna revisión es tiempo perdido ya que igualmente forma parte del proceso de auditoría.

El dato más relevante para el negocio es que solo se escapan 60 sospechosos reales (los falsos negativos que no logró captar el modelo), gastos sospechosos que el modelo aprobó automáticamente sin revisión. Ese número representa el riesgo que la empresa asume al usar el modelo, pero al contar con un recall del 84%, podemos concluir que el modelo sería de gran utilidad para resolver el problema que presenta la empresa.

Modelo ganador: Gradient Boosting

Elegimos el modelo "Gradient boosting" principalmente por su capacidad de detectar los gastos sospechosos reales, lo que minimiza los falsos negativos el cual sería el error más costoso de cometer.

Los otros 2 modelos han sido descartados por su rendimiento al momento de evaluarlos, "Logistic regression" ha sido inferior a "Gradient boosting" tanto en su entrenamiento como a la hora de evaluarlo. Pero "Random forest" parecía ser el modelo por excelencia a la hora de entrenarlo, ya que sus métricas eran

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

sobresalientes, sin embargo, a la hora de evaluarlo, sus métricas eran decepcionantes. Entendemos que esto sucede porque al entrenar, el modelo “aprendió las respuestas de memoria” y no aprendió a detectar patrones reales para clasificar los gastos como sospechosos o no sospechosos.

Paso 7: Interpretación de predicciones

Comparación hipótesis y resultados

Hipótesis 1: Aprovechamiento del tope de política

El modelo confirmó que el ratio entre monto declarado y límite de política es uno de los predictores más fuertes de sospecha. Pero más allá de la confirmación estadística, este hallazgo revela algo importante sobre la naturaleza del sospechoso: no se trata de descuidos ni errores, sino de una conducta deliberada. El empleado conoce la política, sabe hasta dónde puede llegar, y declara un monto estratégicamente cercano al tope para maximizar el beneficio sin disparar alertas. Esto convierte al fraude de viáticos en un problema de diseño de política: si el tope es conocido y predecible, también es explotable.

Hipótesis 2: Falta de comprobante

La ausencia de comprobante casi duplica la probabilidad de sospecha (15,6% vs 38,2%), confirmando que es una de las señales más claras del dataset. Sin embargo, analizar esta variable de forma aislada esconde una parte importante de la historia: no todos los gastos sin comprobante representan el mismo riesgo. Un gasto sin comprobante de \$8.000 puede ser un remis sin factura, pero uno de \$150.000 es una irregularidad muy alta que el equipo auditor no tiene forma de verificar.

Esto llevó a crear la variable **sin_comp_alto_monto**, que combina la ausencia de comprobante con montos que superan el percentil 75 del dataset. La lógica es que ambas señales por separado aportan información, pero juntas capturan un riesgo cualitativamente distinto: el sospechoso que aprovecha deliberadamente la falta de trazabilidad en montos significativos. Esta decisión de feature engineering refleja que el sospechoso sin comprobante no es uniforme, sino que escala con el monto declarado, y que el modelo necesitaba esa distinción para detectarlo correctamente. Este hallazgo tendrá su traducción directa en una recomendación concreta de negocio en el próximo punto.

Cierre

En conjunto, el EDA anticipó correctamente las señales más relevantes: el ratio monto/límite y la ausencia de comprobante resultaron ser los predictores más poderosos, y ambos fueron incorporados al modelo. Las hipótesis que no se confirmaron, como el horario fuera de oficina o la jerarquía del empleado, también aportaron al análisis porque descartaron supuestos que podrían haber guiado el modelo a un camino equivocado. Uno de los hallazgos más significativos en este sentido es que el sospechoso no está concentrado en ningún departamento ni nivel jerárquico específico, sino que atraviesa toda la organización.

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

Esto sugiere que el fraude de viáticos es esencialmente un fenómeno individual: no es el área ni el rol lo que predispone a un empleado a cometer un gasto sospechoso, sino decisiones y comportamientos concretos que el modelo logra detectar. Por eso, los controles no deberían focalizarse en perfiles específicos sino aplicarse de forma general, algo que el modelo permite hacer de manera eficiente.

Recomendaciones de Negocio:

1. Alerta automática para gastos que se acercan al tope de política

Nuestro modelo confirmó, que el ratio entre el monto declarado y el límite de política es uno de los predictores más fuertes de sospecha, lo que revela que una parte del fraude es deliberada, aprovechando los topes conocidos. Para actuar sobre esto de una forma preventiva, recomendamos implementar un alerta automático en el sistema de viáticos cuando el gasto supera los 85% del límite permitido por categoría. Esto permitiría una revisión **antes** de que se apruebe el gasto. Así podemos convertir la revisión de un acto puramente reactivo a una acción proactiva, y eso dificultará el fraude estratégico de declarar montos cercanos al tope permitido.

2. Obligatoriedad de comprobante a partir de cierto monto

Los gastos con ausencia de comprobante casi duplican la probabilidad de sospecha, y nuestro análisis mostró, que ese riesgo escala notablemente con un monto declarado alto. Por eso es que proponemos como medida hacer obligatorio que los gastos estén respaldados por comprobante, especialmente aquellos que están cerca o por encima del límite establecido por la empresa.

3. Formalizar y digitalizar el proceso de pago

Se requerirá aprobación previa obligatoria para cualquier gasto realizado los domingos o fuera del horario de oficina, exigiendo al empleado una justificación documentada y el aval de un superior antes de incurrir en el gasto.

Complementariamente, el sistema de gestión de gastos generará alertas automáticas que marcarán como "a revisar" todo comprobante cargado bajo esas mismas condiciones, permitiendo al equipo de control enfocarse en los casos de mayor riesgo de forma eficiente. re

Impacto económico del modelo: ejemplo con datos reales

Para dimensionar el valor real del modelo, tomamos los datos del dataset como si fueran los gastos de viáticos de un período fiscal de la empresa. El dataset contiene 10.000 gastos rendidos, de los cuales 1.901 son sospechosos, representando ARS 178.360.659 en montos potencialmente sospechosos, con un monto promedio de ARS 93.825 por gasto sospechoso.

Escenario sin modelo:

Sin el modelo, el equipo de Auditoría Interna debería revisar manualmente los 10.000 gastos para encontrar los 1.901 sospechosos. Esto implica un enorme costo de tiempo y

Grupo 4: Tomas Bruni, Mateo Ritondale, Santiago Estevez, Nicolas Colonna, Alexandre Bourdin, Maximilian Paul

recursos humanos, además se corre el riesgo de que auditores fatigados pasen por alto casos de sospecha real.

Escenario con Random Forest:

Con nuestro modelo de machine learning, los empleados pasarían de revisar el 100% de los gastos a tan solo el 38,4%(proporción marcada como sospechosa en “test”) de los casos (suponiendo que sean revisados todos los gastos que nuestro modelo identifica como sospechosos). Esto reduciría notablemente el tiempo empleado en la tarea.

Si tomamos como referencia los gastos sospechosos con los que contamos actualmente, la empresa ahorraría aproximadamente **\$ 150.536.396,37324** pesos, es decir el 84,4% de los gastos