
TRABAJO PRÁCTICO · SMALL DATA

Detección de **Fraude** en Viáticos

Un modelo de clasificación para que
Auditoría Interna enfoque la revisión
manual en los gastos de mayor riesgo.

10.000 gastos
analizados



Quiénes somos

RM

Ritondale

Mateo

MP

Paul

Maximilian

BA

Bourdin

Alexandre

ES

Estevez

Santiago

CN

Colonna

Nicolás

BT

Bruni

Tomás

Fraudes Viáticos

10.000

Filas (gastos rendidos)

14

Columnas + 2 meta

2

Clases · binaria (0 / 1)

Recall

Métrica objetivo

77% · Legítimo

23% · Sospechoso

Valor 0 — gasto legítimo

Valor 1 — sospechoso/requiere revisión

- Target **gasto_sospechoso**, es un dato desbalanceado en el data set
- Un problema de **clasificación binaria** .

EL DINERO EN JUEGO

~\$180M

ARS bajo sospecha de fraude — el 22,6% del gasto total rendido

CATEGORÍA	MONTO ARS	% DEL TOTAL
■ Gasto legítimo	609.462.678	77%
■ Gasto sospechoso	178.360.659	23%
Total rendido	787.823.337	100%

Cada gasto sospechoso no detectado sale directo del presupuesto de viáticos

Predecir si un gasto es sospechoso para enfocar la revisión manual

FALSO POSITIVO

Un gasto legítimo marcado como sospechoso: se pierde **únicamente el tiempo** de un auditor — un costo de oportunidad.

FALSO NEGATIVO

Un sospechoso que pasa sin revisión: la empresa **pierde dinero del presupuesto**, el abuso se repite y es difícil recuperarlo.

Priorizamos Recall

El falso negativo es el error más costoso. El modelo debe atrapar la mayor cantidad posible de sospechosos, aunque se revisen gastos no sospechosos para lograrlo.

Hipótesis

H1 PASO 3 · EDA

Límite de política

Los gastos que superan el tope permitido por la política tienen más probabilidad de ser sospechosos. Creemos que se declara el gasto justo por debajo del límite y se quedan con la diferencia.

<1


No supera el límite

≥1

Roza o supera el tope

Box Plot · `ratio = gasto / límite de política`

Histograma: Probabilidad de gasto sosp. dado ratio



H2 PASO 3 · EDA

Monto declarado

La probabilidad de un gasto sospechoso es mucho más alta cuando el monto declarado es mayor. A partir de los 250.000 ARS la probabilidad casi se duplica.


~20%

Montos < 250.000 ARS

~40%

Montos > 250.000 ARS

Histograma · prob. de sospecha según monto



H3

PASO 3 · EDA


Comprobante

Si el gasto no tiene comprobante asociado , es más probable que sea sospechoso y por ende requiera ser revisado. Sin comprobante, el riesgo más que se duplica.

~15,6%
Con comprobante

~38,2%
Sin comprobante

Histograma · prob. de sospecha según comprobante



H4 PASO 3 · EDA

Fuera de horario


- Los gastos fuera del horario de oficina tienen más probabilidad de ser sospechosos, ya que no hay personas que revisen esos gastos en el momento.
- Sin embargo descartamos esta hipótesis como un factor fuerte, ya que al observar los datos vemos que no hay mucha diferencia en las probabilidades

~18%

Sospechoso

~82%

No sospechoso



Histograma · prob. de sospecha según horario

Hallazgos


HALLAZGOS

Lo que nos sorprendió...

Día de semana

+10 PUNTOS PORCENTUALES LOS DOMINGOS


Los domingos son más sospechosos: 27% de gastos sospechosos, contra un promedio cercano al 17% durante la semana.



Historial de rechazos

CONTRA-INTUITIVO

Sorpresa: haber sido rechazado antes **no** aumenta el riesgo. La sospecha se mantiene igual sin importar los rechazos previos.





HALLAZGOS

Lo que nos sorprendió...

Jerarquía y departamentos

La probabilidad de gasto sospechoso según Jerarquía o departamento se distribuye de manera casi equitativa entre las variables, esto nos da a entender que es un problema que cruza transversalmente a toda la empresa.




HALLAZGOS

Lo que nos sorprendió...

Metodo de pago


CONTRA-INTUITIVO

Como es más difícil de controlar los gastos en efectivo, creiamos que los mismos iban a ser más sospechosos, pero los datos nos mostraron lo contrario.



Cuit válido

También sospechamos que un gasto sin cuit o cuit ficticio (ej: 1234...), sería un fuerte indicio de un gasto sospechoso, pero una vez más, los datos probaron lo contrario.



CONCLUSIÓN DEL EDA

Las variables con mayor poder predictivo

Las candidatas a alimentar el modelo de clasificación.

01 `monto_declarado_ars`

02 `ratio_monto_limite`

03 `tiene_comprobante`

04 `dia_semana`

Próximos pasos

- Preprocesamiento y selección de variables
- Modelado: Regresión Logística, Random Forest y Gradient Boosting.
- Evaluación: comparar Recall, AUC, F1 y matriz de confusión.
- Validar hipótesis

Preprocesamiento y selección de variables

Limpieza & Transformación de datos

Variable original	Cambio realizado	Justificación
Id_gasto	convertido a Metadata	identificador único, no aporta capacidad predictiva al modelo
tiene_comprobante (Sí/No)	Recodificado a 1/0	facilita el preprocesamiento por parte de los algoritmos
fecha_gasto	Estandarización de formato	se unificaron formtos inconsistentes para garantizar calidad de datos
cuit_proveedor	validación y creacion de identificador binario	formatos invalidos calculan un nuevo flag binario; podria asociarse con un comportamiento sospechoso

Feature Engineering

Categoria	Variable creada	Objetivo
Control de límites de politica	excede_limite & ratio_monto_limite	identificar que gastos superan el tope autorizado, y medir que tan cerca están del máximo permitido
Comportamiento temporal	es_domingo & fuera_horario	detectar gastos fuera del horario laboral; e intentar capturar el patrón observado en el EDA (mayor proporción de sospecha los domingos)
Calidad de documentación	cuit_valido	detectar inconsistencias/errorer en la identificación del proveedor
Calidad de documentación	sin_comp_alto_monto	identifica gastos con combinación doble de riesgo: monto alto y ausencia de documentación

Selección de Variables

Variables eliminadas por redundancia:

- categoria_gasto

Motivo: información ya representada por limite_politic_ars

Variables eliminadas por bajo aporte

predictivo:

- departamento
- distancia_oficina_km
- comentarios_longitud
- sin_comp_alto_monto
- es_domingo

Motivo: baja correlacion con gastos
sospechosos; empeoraban desempeño del
modelo

Objetivo: reducir ruido y mantener únicamente variables que aportaran valor predictivo.


Analisis de outliers

Hallazgos:

- se detectaron valores extremos, en varias variables
- ningno resultó imposible o inconsistente
- algunos representan señales potenciales de fraude.

Decisión: No eliminar

- casos plausibles dentro del negocio
- aportan información relevante
- permiten aprender comportamiento sospechoso extremo



Modelado

Selección de variables predictivas:

Modelos evaluados:


- Random forest
- Logistic regression
- Gradient boosting

Balanceo de datos:

En un principio buscamos balancear los datos para el entrenamiento con las características del modelo (como "balance class distribution") pero era ineficiente, por lo que decidimos usar un script de python que nos permitio aumentar el numero de gastos sospechosos (Oversampling)

Running script:

```
Legítimos : 6483
Fraudes : 1517
A generar : 4966
Total final: 12966
Fraudes finales : 6483
Legítimos finales : 6483
```



Evaluación

Metricas

- **AUC:** Mide qué tan bien el modelo distingue un gasto sospechoso de uno legítimo en general
- **Precision:** De todos los gastos que el modelo marcó como sospechosos, ¿cuántos realmente lo eran?
- **Recall:** De todos los gastos sospechosos reales que existen en el dataset, ¿cuántos detectó correctamente el modelo?
- **F1:** Balance entre Precision y Recall, si existe una gran diferencia entre estas 2 habra un gran castigo

TEST AND SCORE

• NO SOSPECHOSO

Evaluation results for target 0						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest (2)	0.988	0.924	0.920	0.975	0.871	0.854
Gradient Boosting (1)	0.834	0.787	0.774	0.822	0.731	0.577
Logistic Regression	0.750	0.693	0.670	0.723	0.624	0.389

• PROMEDIO

Evaluation results for target (None, show average over classes)						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest (2)	0.988	0.924	0.924	0.929	0.924	0.854
Gradient Boosting (1)	0.833	0.787	0.786	0.790	0.787	0.577
Logistic Regression	0.750	0.693	0.691	0.696	0.693	0.389

• SOSPECHOSO

Evaluation results for target 1						
Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest (2)	0.988	0.924	0.928	0.884	0.978	0.854
Gradient Boosting (1)	0.834	0.787	0.798	0.758	0.842	0.577
Logistic Regression	0.750	0.693	0.712	0.669	0.761	0.389

PREDICTIONS

- PROMEDIO

☒ Show performance scores		Target class: (Average over cl				
Model	AUC	CA	F1	Prec	Recall	MCC
Gradient Boosting (1)	0.813	0.748	0.773	0.850	0.748	0.461
Random Forest (2)	0.800	0.801	0.803	0.805	0.801	0.370
Logistic Regression	0.749	0.636	0.675	0.800	0.636	0.293

- NO SOSPECHOSO

☒ Show performance scores		Target class: 0				
Model	AUC	CA	F1	Prec	Recall	MCC
Gradient Boosting (1)	0.813	0.748	0.823	0.951	0.725	0.461
Random Forest (2)	0.800	0.801	0.876	0.881	0.871	0.370
Logistic Regression	0.749	0.636	0.729	0.916	0.605	0.293

- SOSPECHOSO

☒ Show performance scores		Target class: 1				
Model	AUC	CA	F1	Prec	Recall	MCC
Gradient Boosting (1)	0.813	0.748	0.562	0.422	0.844	0.461
Random Forest (2)	0.800	0.801	0.494	0.483	0.505	0.370
Logistic Regression	0.749	0.636	0.447	0.315	0.766	0.293

RANDOM FOREST

TEST AND SCORE

Predicted			
	0	1	Σ
0	2827	418	3245
1	72	3173	3245
Σ	2899	3591	6490

PREDICTIONS

Predicted			
	0	1	Σ
0	1408	208	1616
1	190	194	384
Σ	1598	402	2000

LOGISTIC REGRESION

TEST AND SCORE

Predicted			
	0	1	Σ
0	2026	1219	3245
1	776	2469	3245
Σ	2802	3688	6490

PREDICTIONS

Predicted			
	0	1	Σ
0	978	638	1616
1	90	294	384
Σ	1068	932	2000



GRADIENT BOOSTING

TEST AND SCORE

Predicted			
	0	1	Σ
0	2372	873	3245
1	512	2733	3245
Σ	2884	3606	6490

PREDICTIONS

Predicted			
	0	1	Σ
0	1172	444	1616
1	60	324	384
Σ	1232	768	2000

Interpretación y acción

Acciones recomendadas

01 Alerta automática al 85% del tope

Disparar una revisión **antes de aprobar** el gasto cuando alcanza el 85% del monto límite. Esto con el fin de evitar precios “inflados” y que los empleados se aprovechen de la política

02 Comprobante obligatorio

Exigir comprobante para todos los gastos antes de aprobarlos, especialmente para aquellos de montos altos o por encima del límite establecido por la empresa

03 Autorización preva para gastos en domingos y horarios fuera de la oficina

Se necesitará autorización previa para rendir gastos los días domingos u horarios fuera de la oficina. Complementariamente, podría generarse una alerta para los gastos que cumplen esas condiciones para ser revisados

El valor del modelo

(Tomando como referencia la totalidad de los datos)

Carga de trabajo: De revisar 10.000 gastos a solo 2.103 marcados.

-62,6%

Fraudes que escapan: solo ARS 3,94M fuera del radar del modelo.

296 (15,625%)

Fraudes detectados: sobre el total real de gastos sospechosos.

1.605/ 1.901 (84,4%)

Ahorro económico: por detectar el 84,4% de los gastos sospechosos

\$ 150.536.396,37324 pesos

¡Muchas gracias!